

UNIVERSIDAD NACIONAL DEL ALTIPLANO
FACULTAD DE INGENIERÍA ESTADÍSTICA E INFORMÁTICA



AUTOCORRELACIÓN ESPACIAL
ÍNDICE DE MORAN APLICADO A MÚLTIPLES DATASETS REALES EN
SHINY

Estudiante: CHOQUE ZUÑIGA Clever Nelson

Docente: TORRES CRUZ FRED

Curso: Estadística Espacial

Grupo: B

Semestre: XI 2026-I

Puno – Perú

2026

Índice

1. Introducción	2
2. Marco Teórico	2
2.1. Fórmula del Índice de Moran	2
2.2. Hipótesis y valor esperado	2
2.3. Diagrama de dispersión de Moran	3
2.4. Test de Monte Carlo	3
2.5. Matriz de pesos espaciales	3
3. Datasets Analizados	3
4. Resultados por Dataset	4
4.1. Dataset 1 — North Carolina: Tasa de Mortalidad SIDS	4
4.2. Dataset 2 — Nueva Zelanda: Ingreso Mediano Regional	5
4.3. Dataset 3 — Meuse: Concentración de Zinc en Suelo	7
4.4. Dataset 4 — Boston: Valor Mediano de Viviendas	8
4.5. Dataset 5 — Francia 1830: Criminalidad contra la Propiedad	9
5. Resultados Comparativos	11
5.1. Tabla Resumen Global	11
5.2. Comparación Visual	12
6. Discusión	12
6.1. Coherencia entre test normal y Monte Carlo	12
6.2. Efecto del tamaño muestral	13
6.3. Naturaleza del fenómeno y magnitud de I	13
6.4. Limitaciones	13
7. Conclusiones	13
8. Anexos	15

Introducción

La autocorrelación espacial mide el grado en que los valores de una variable en una ubicación geográfica se relacionan con los valores de esa misma variable en ubicaciones cercanas. El principio de Tobler (1970), conocido como la primera ley de la geografía, lo enuncia con claridad: «*todo está relacionado con todo lo demás, pero las cosas cercanas están más relacionadas que las distantes*».

El **Índice de Moran** (I), propuesto por P. A. P. Moran en 1950, es el estadístico global más utilizado para cuantificar este fenómeno. Cuando $I > \mathbb{E}[I]$ con $p < 0,05$ existe un patrón de *clustering* (valores similares agrupados); cuando $I < \mathbb{E}[I]$ con $p < 0,05$, el patrón es disperso (valores opuestos entre vecinos); y cuando no se rechaza H_0 , la distribución es consistente con la aleatoriedad espacial.

En el presente informe se aplica este análisis sobre **cinco datasets reales** de disciplinas distintas, empleando R con los paquetes **spdep**, **sf** y **ggplot2**, con el objetivo de evidenciar la versatilidad del Índice de Moran y comparar los patrones espaciales obtenidos.

Marco Teórico

Fórmula del Índice de Moran

$$I = \frac{n}{S_0} \cdot \frac{\sum_{i=1}^n \sum_{j=1}^n w_{ij} (x_i - \bar{x})(x_j - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (1)$$

donde n es el número de unidades espaciales, w_{ij} es el elemento de la matriz de pesos espaciales W y $S_0 = \sum_i \sum_j w_{ij}$.

Hipótesis y valor esperado

Bajo la hipótesis nula de aleatoriedad espacial completa:

$$H_0 : \text{los valores se distribuyen aleatoriamente en el espacio} \quad (2)$$

$$\mathbb{E}[I] = -\frac{1}{n-1} \longrightarrow 0 \text{ cuando } n \rightarrow \infty \quad (3)$$

Diagrama de dispersión de Moran

El diagrama grafica el valor estandarizado $z_i = (x_i - \bar{x})/s$ en el eje X contra el rezago espacial $Wz_i = \sum_j w_{ij}z_j$ en el eje Y . La pendiente de la recta de regresión es aproximadamente igual a I . Los cuatro cuadrantes identifican los patrones LISA locales:

Cuadrante	Notación	Descripción
$z > 0, Wz > 0$	HH	Clúster de valores altos
$z < 0, Wz < 0$	LL	Clúster de valores bajos
$z > 0, Wz < 0$	HL	Valor alto rodeado de bajos (outlier espacial)
$z < 0, Wz > 0$	LH	Valor bajo rodeado de altos (outlier espacial)

Test de Monte Carlo

Para evitar el supuesto de normalidad, se permutan aleatoriamente los valores entre las unidades N_{sim} veces. El p -valor empírico es:

$$p = \frac{\#\{I_{\text{perm}} \geq I_{\text{obs}}\} + 1}{N_{\text{sim}} + 1} \quad (4)$$

En este trabajo se emplearon $N_{\text{sim}} = 499$ permutaciones con semilla 123.

Matriz de pesos espaciales

- **Contigüidad Reina (Queen):** vecinos que comparten arista o vértice — usada para polígonos.
- **K -vecinos más cercanos (KNN, $k = 5$):** los 5 puntos más próximos — usada para datos puntuales.

En ambos casos se aplica estandarización por filas: $\sum_j w_{ij} = 1 \forall i$.

Datasets Analizados

#	Dataset	Variable	n	Vecindad	Fuente R
1	North Carolina, EE.UU.	Tasa SIDS (por 1000 nac.)	100	Queen	<code>sf::nc.shp</code>
2	Nueva Zelanda	Ingreso mediano (NZD)	16	Queen	<code>spData::nz</code>
3	Río Meuse, Holanda	$\log(\text{Zinc en suelo, ppm})$	155	KNN-5	<code>sp::meuse</code>
4	Boston, MA, EE.UU.	Valor vivienda (miles USD)	506	KNN-5	<code>MASS::Boston</code>
5	Francia, 1830	Índice crimen propiedad	85	Queen	<code>Guerry::gfrance8</code>

Cuadro 1: Descripción de los cinco datasets analizados

Resultados por Dataset

Dataset 1 — North Carolina: Tasa de Mortalidad SIDS

El dataset contiene información de los 100 condados de Carolina del Norte. La variable analizada es la tasa de muertes por síndrome de muerte súbita infantil (SIDS) por cada 1 000 nacidos vivos en el período 1974–1978, calculada como $\text{SIDS_RATE} = (\text{SID74}/\text{BIR74}) \times 1000$.

Resultados — North Carolina SIDS

Índice de Moran observado:	$I = 0,2309$
Valor esperado bajo H_0 :	$\mathbb{E}[I] = -0,0101$
Varianza bajo H_0 :	$\text{Var}[I] = 0,004065$
p -valor (normalidad):	$p = 0,0001$
p -valor (Monte Carlo):	$p = 0,002$
Conclusión:	Cluster positivo (+)

N. Carolina - Tasa SIDS | $I=0.2309$ | $p(\text{MC})=0.002$ -> Cluster (+)




Figura 1: Panel de análisis espacial — North Carolina: Tasa SIDS. Arriba: mapa de calor de la variable y cuadrantes LISA. Abajo: diagrama de dispersión de Moran y distribución Monte Carlo.

El valor $I = 0,2309$ es considerablemente mayor que $E[I] = -0,0101$, con un p -valor Monte Carlo de 0,002, lo que permite rechazar con contundencia la hipótesis de aleatoriedad espacial. Los condados con tasas SIDS elevadas tienden a agruparse en el centro-este y sur del estado (cuadrante HH en azul), mientras que el noroeste concentra condados con tasas bajas rodeados de vecinos igualmente bajos (cuadrante LL en verde claro). El diagrama de Moran muestra una pendiente positiva clara y la distribución Monte Carlo confirma que el I observado se ubica en el extremo derecho de la distribución nula, muy lejos de cualquier permutación aleatoria.

Dataset 2 — Nueva Zelanda: Ingreso Mediano Regional

El objeto `nz` contiene las 16 regiones administrativas de Nueva Zelanda. La variable es el ingreso mediano en dólares neozelandeses (NZD).

Resultados — Nueva Zelanda Ingreso Mediano

Índice de Moran observado:	$I = -0,3463$
Valor esperado bajo H_0 :	$\mathbb{E}[I] = -0,0667$
Varianza bajo H_0 :	$\text{Var}[I] = 0,039435$
p -valor (normalidad):	$p = 0,9204$
p -valor (Monte Carlo):	$p = 0,928$
Conclusión:	Aleatorio (no significativo)




Figura 2: Panel de análisis espacial — Nueva Zelanda: Ingreso Mediano. Se observa un I negativo pero estadísticamente no significativo.

Con $p = 0,928$ no existe evidencia suficiente para rechazar la hipótesis nula. El valor negativo $I = -0,3463$ sugeriría una leve tendencia dispersa (regiones ricas adyacentes a pobres), pero con solo $n = 16$ unidades la potencia estadística es muy baja: la alta varianza $\text{Var}[I] = 0,039$ refleja la inestabilidad del estimador. En el histograma Monte Carlo se aprecia que el I observado cae prácticamente en el centro de la distribución de permutaciones (la línea naranja coincide con la masa principal de barras rojas), lo que confirma que el resultado es compatible con el azar.

Dataset 3 — Meuse: Concentración de Zinc en Suelo

El dataset `meuse` contiene 155 muestras de suelo tomadas en la llanura de inundación del río Meuse (Países Bajos). Se analiza el logaritmo de la concentración de zinc en partes por millón — la transformación logarítmica estabiliza la varianza de la distribución sesgada original.

Resultados — Meuse log(Zinc)

Índice de Moran observado:	$I = 0,5291$
Valor esperado bajo H_0 :	$\mathbb{E}[I] = -0,0065$
Varianza bajo H_0 :	$\text{Var}[I] = 0,002099$
p -valor (normalidad):	$p \approx 0$
p -valor (Monte Carlo):	$p = 0,002$
Conclusión:	Cluster positivo (+) — intenso




Figura 3: Panel de análisis espacial — Meuse: log(Zinc en suelo). Fuerte autocorrelación positiva. Nótese que el mapa de puntos no muestra geometría de polígono pues se trata de datos puntuales con vecindad KNN-5.

Este es el valor más alto de autocorrelación del estudio ($I = 0,5291$). Las muestras próximas al cauce principal del Meuse concentran las mayores cantidades de zinc (cua-

drante HH), consecuencia directa de la deposición sedimentaria durante inundaciones. Las zonas alejadas del río presentan concentraciones bajas agrupadas (cuadrante LL). El diagrama de Moran muestra la pendiente positiva más pronunciada del estudio, y en la distribución Monte Carlo el I observado se ubica completamente separado de cualquier permutación aleatoria — ninguna de las 499 permutaciones superó el valor observado.

Dataset 4 — Boston: Valor Mediano de Viviendas

El clásico dataset de Harrison y Rubinfeld (1978) contiene 506 zonas censales de Boston. La variable `medv` es el valor mediano de viviendas en miles de dólares estadounidenses.

Resultados — Boston Valor de Vivienda

Índice de Moran observado:	$I = 0,4651$
Valor esperado bajo H_0 :	$\mathbb{E}[I] = -0,0020$
Varianza bajo H_0 :	$\text{Var}[I] = 0,000697$
p -valor (normalidad):	$p \approx 0$
p -valor (Monte Carlo):	$p = 0,002$
Conclusión:	Cluster positivo (+) — intenso




Figura 4: Panel de análisis espacial — Boston: Valor mediano de viviendas. El gran tamaño muestral ($n = 506$) produce una varianza muy baja del estimador.

Con $I = 0,4651$ y $p = 0,002$, existe una fuerte segregación espacial del valor inmobiliario en Boston. Las zonas con viviendas de alto valor se concentran geográficamente (cuadrante HH), así como las zonas de bajo valor (cuadrante LL). El gran tamaño muestral ($n = 506$) produce una varianza muy baja del estimador ($Var[I] = 0,000697$), lo que confiere alta potencia al test. En el histograma Monte Carlo, la línea del I observado aparece totalmente fuera del rango de las permutaciones, evidenciando un patrón espacial imposible de explicar por el azar.

Dataset 5 — Francia 1830: Criminalidad contra la Propiedad

El dataset `gfrance85` de Guerry (1833) contiene estadísticas de los 85 departamentos franceses. La variable `Crime_prop` es un índice de criminalidad contra la propiedad del período posrevolucionario.

Resultados — Francia 1830 Crimen Propiedad

Índice de Moran observado:	$I = 0,2636$
Valor esperado bajo H_0 :	$\mathbb{E}[I] = -0,0119$
Varianza bajo H_0 :	$\text{Var}[I] = 0,004662$
p -valor (normalidad):	$p \approx 0$
p -valor (Monte Carlo):	$p = 0,002$
Conclusión:	Cluster positivo (+)




Figura 5: Panel de análisis espacial — Francia 1830: Índice de crimen contra la propiedad. Los departamentos del norte y entorno parisino muestran agrupamiento HH.

Los departamentos del norte de Francia y el entorno parisino muestran los índices de criminalidad más elevados agrupados (cuadrante HH, azul), coherente con la mayor densidad urbana y las desigualdades económicas del período. El sur y las regiones periféricas concentran índices bajos rodeados de vecinos igualmente bajos (LL, verde claro). El diagrama de Moran presenta una pendiente positiva moderada con algunos outliers espaciales (cuadrante HL) que corresponden a departamentos fronterizos o con características demográficas atípicas.

Resultados Comparativos

Tabla Resumen Global

Dataset	n	I obs.	$\mathbb{E}[I]$	p norm.	p MC	Resultado
N. Carolina — SIDS	100	0,2309	−0,0101	0,0001	0,002	Cluster (+)
Nueva Zelanda — Ingreso	16	−0,3463	−0,0667	0,9204	0,928	Aleatorio
Meuse — log(Zinc)	155	0,5291	−0,0065	< 0,001	0,002	Cluster (+)
Boston — Valor vivienda	506	0,4651	−0,0020	< 0,001	0,002	Cluster (+)
Francia 1830 — Crimen	85	0,2636	−0,0119	< 0,001	0,002	Cluster (+)

Cuadro 2: Resumen del Índice de Moran para los cinco datasets. Test MC con 499 permutaciones y semilla 123.

Comparación Visual




Figura 6: Comparación del Índice de Moran observado en los cinco datasets. Barras azules indican resultados estadísticamente significativos ($p < 0,05$); barra gris indica resultado no significativo. Vecindad queen/KNN, Monte Carlo 499 permutaciones.

La Figura 8 muestra con claridad el gradiente de intensidad del agrupamiento espacial:

$$I_{\text{Meuse}}(0,5291) > I_{\text{Boston}}(0,4651) > I_{\text{Francia}}(0,2636) > I_{\text{NC}}(0,2309) \gg I_{\text{NZ}}(-0,3463) \quad (5)$$

Los cuatro datasets con $p < 0,05$ confirman que el agrupamiento espacial es una propiedad generalizada en fenómenos geográficos de naturaleza muy distinta: física (dispersión de contaminantes), socioeconómica (valor inmobiliario), histórica (criminalidad) y epidemiológica (mortalidad infantil).

Discusión

Coherencia entre test normal y Monte Carlo

En todos los datasets ambos métodos coinciden en la decisión ($p < 0,05$ o $p \geq 0,05$), lo que sugiere que los supuestos del test normal se cumplen razonablemente. No obstante,

el test Monte Carlo es preferible en la práctica porque no requiere asumir normalidad ni conocer la distribución exacta de I .

Efecto del tamaño muestral

El caso de Nueva Zelanda ($n = 16$) ilustra un problema fundamental: la baja potencia estadística cuando el número de unidades es pequeño. Aunque $I = -0,3463$ dista sustancialmente de $\mathbb{E}[I] = -0,0667$, la alta varianza del estimador ($\text{Var}[I] = 0,039$) impide rechazar H_0 . Se requeriría una muestra mayor o un enfoque distinto (e.g., análisis de componentes espaciales) para extraer conclusiones firmes.

Naturaleza del fenómeno y magnitud de I

Los procesos físicos continuos (dispersión de zinc por sedimentación fluvial en Meuse) producen mayor autocorrelación que los fenómenos socioeconómicos, que a su vez superan a los histórico-criminológicos y epidemiológicos. Esto responde a la escala de operación de cada proceso: la sedimentación actúa a escala de metros, mientras que la mortalidad infantil depende de factores a escala de condados que pueden ser más heterogéneos.

Limitaciones

1. **Boston:** las coordenadas utilizadas son una grilla regular sintética al no disponer de las coordenadas reales de los tracts censales, por lo que la estructura espacial es una aproximación.
2. **Índice global:** el I de Moran resume en un escalar toda la estructura espacial. Para detectar clústeres locales específicos se requieren indicadores LISA locales mediante `localmoran()` en `spdep`.
3. **Sensibilidad a W :** diferentes esquemas de vecindad pueden producir valores de I distintos, por lo que la elección de la matriz de pesos no es neutral.

Conclusiones

1. El **Índice de Moran** demostró ser aplicable a fenómenos geográficos de naturaleza muy diversa: epidemiológica, económica, ambiental, inmobiliaria e histórica, con resultados interpretables y coherentes en todos los casos.
2. **Cuatro de los cinco datasets** presentaron autocorrelación espacial positiva

estadísticamente significativa ($p = 0,002$ en todos los casos con Monte Carlo), rechazando la hipótesis de aleatoriedad y confirmando que los valores similares tienden a agruparse geográficamente.

3. El mayor valor de I correspondió al **Meuse** ($I = 0,5291$), donde la concentración de zinc sigue directamente el gradiente físico de distancia al cauce del río. El menor valor significativo correspondió a **North Carolina** ($I = 0,2309$), donde los factores socioeconómicos que condicionan la mortalidad SIDS operan a escalas más heterogéneas.
4. El único caso no significativo (**Nueva Zelanda**, $p = 0,928$) se atribuye principalmente al reducido número de unidades espaciales ($n = 16$), que genera alta varianza en el estimador y baja potencia estadística, imposibilitando la detección de patrones aunque pudieran existir.
5. El **test de Monte Carlo** con 499 permutaciones fue coherente con el test asintótico normal en todos los datasets, validando ambas aproximaciones para este tipo de datos.
6. La implementación en R con **spdep** y **sf** permite obtener un análisis completo, reproducible y visualizable que incluye mapa de calor, cuadrantes LISA, diagrama de dispersión de Moran y distribución Monte Carlo, consolidados en un único panel por dataset.

Anexos




Figura 7: imagen 1 aplicativo shiny.




Figura 8: imagen 2 aplicativo Shiny.