

Variabilidad espacial de índices de vegetación (NDVI, EVI, SAVI y NDMI) en la región de Puno mediante krigeado ordinario e indicativo: comparación entre estación seca y estación húmeda

Denilzon Robin Tapara Tristan, Clever Nelson Choque Zuñiga
, Rene Rolando Ccoyto Pachapuma, and Yimmy Cristhian Morocco Apaza

¹ Universidad Nacional del Altiplano, Puno, Peru ² Universidad Nacional del Altiplano, Puno, Peru
dtaparat@est.unap.edu.pe cn.choque@est.unap.edu.pe

³ Universidad Nacional del Altiplano, Puno, Peru ⁴ Universidad Nacional del Altiplano, Puno, Peru
rccoyto@est.unap.edu.pe ymoroco@est.unap.edu.pe

Abstract. La variabilidad espacial de la cobertura vegetal en ecosistemas altoandinos constituye un insumo relevante para la gestión ambiental y territorial. El presente trabajo replica y extiende, para la región de Puno, Perú, el enfoque geoestadístico propuesto por Lourenço y Landim (2004) [18] para el análisis de la variabilidad del NDVI mediante krigeado indicativo. Se incorporan tres índices espectrales complementarios –EVI, SAVI y NDMI– obtenidos de imágenes Sentinel-2 SR Harmonized, y se contrastan dos estaciones del mismo ciclo anual: seca (mayo–agosto de 2024) y húmeda (diciembre de 2023 – marzo de 2024). A partir de 500 puntos de muestreo aleatorio por estación se ajustaron semi-variogramas experimentales, se interpoló mediante krigeado ordinario sobre una grilla de 2 km (16 850 nodos) y se aplicó krigeado indicativo con dos niveles de corte definidos por los terciles empíricos del NDVI. Los resultados evidencian una marcada estacionalidad en la *estructura* de la dependencia espacial: en estación seca los alcances son de escala regional (≈ 108 km para NDVI y SAVI), mientras que en estación húmeda se reducen a escala local (≈ 16 km to 17 km), pese a que las medias del índice son prácticamente idénticas entre ambos periodos. El krigeado indicativo clasificó el 49.5 % del territorio como categoría Alta en estación seca frente al 53.1 % en estación húmeda, expansión que ocurre a pesar de que el umbral que define dicha categoría es más exigente en el periodo lluvioso.

Keywords: NDVI · EVI · SAVI · NDMI · Krigeado Ordinario · Krigeado Indicativo · Geoestadística · Sensoriamento Remoto · Puno

1 Introducción

El monitoreo de la cobertura vegetal mediante sensores remotos se ha convertido en una herramienta central para la gestión ambiental, en particular en ecosistemas de montaña donde el acceso a campo es limitado y la variabilidad topográfica y climática es muy alta. En la región altoandina de Puno, ubicada sobre los 3800 m s.n.m. en gran parte de su territorio, la vegetación natural (pastizales, bofedales, matorrales) responde de forma marcada a gradientes de altitud, precipitación y temperatura, lo que hace de esta zona un caso de estudio particularmente interesante para evaluar cómo se distribuyen espacialmente los índices espectrales de vegetación.

Este trabajo toma como referencia metodológica el estudio de Lourenço y Landim (2004) [18], quienes analizaron la variabilidad del Índice de Vegetación por Diferencia Normalizada (NDVI) en la Baixada Santista (Brasil) mediante krigeado indicativo, comparando imágenes Landsat TM de 1989 y 1997 para generar mapas de probabilidad de pérdida o ganancia de vegetación. Se adapta y amplía dicho enfoque al caso de la región de Puno, con tres diferencias sustantivas respecto al estudio original: se incorporan cuatro índices espectrales en lugar de uno; el contraste no se establece entre dos años distantes sino *entre dos estaciones del mismo ciclo anual*, lo que permite aislar el componente fenológico-climático de la variabilidad; y se emplean imágenes Sentinel-2 de 10 m de resolución en lugar de Landsat 5 TM de 30 m.

El objetivo general es analizar la variabilidad espacial de los índices NDVI, EVI, SAVI y NDMI en la región de Puno mediante krigeado ordinario e indicativo, comparando la estructura de dependencia espacial

entre la estación seca y la estación húmeda. Como objetivos específicos se plantean: caracterizar estadísticamente la distribución de los cuatro índices en ambas estaciones; ajustar y seleccionar modelos teóricos de semivariograma para cada índice y estación; generar mapas continuos de interpolación; y construir, mediante krigeado indicativo, una clasificación de la cobertura vegetal en tres categorías sobre bases probabilísticas.

2 Marco Teórico

2.1 Fundamentos de la Teledetección y la Imagen Digital Satelital

Una imagen satelital está compuesta por una matriz de elementos mínimos (píxeles), cada uno asociado a un valor numérico –el número digital (ND)– que representa la intensidad de energía electromagnética reflejada por la superficie terrestre en una banda espectral determinada. Cuando estos valores se distribuyen sobre el territorio, conforman una función bidimensional $I(x, y)$ que puede tratarse estadísticamente como una *variable regionalizada*, es decir, una variable que varía en el espacio de forma continua pero no completamente aleatoria, ya que valores cercanos tienden a parecerse más entre sí que valores distantes (dependencia espacial) [6].

El comportamiento espectral de la vegetación es lo que permite construir índices sensibles a su estado y vigor. La clorofila de las hojas absorbe fuertemente la radiación en la banda del rojo visible ($\approx 0.63\text{--}0.69\ \mu\text{m}$), mientras que la estructura celular interna de las hojas produce una alta reflectancia en el infrarrojo cercano ($\approx 0.76\text{--}0.90\ \mu\text{m}$). Cuanto mayor es el contraste entre ambas bandas, mayor es el vigor y la densidad de la cobertura vegetal presente en la escena, principio en el que se basan los distintos índices de vegetación [27].

2.2 Índices Espectrales de Vegetación Empleados

NDVI (Índice de Vegetación de Diferencia Normalizada). Propuesto originalmente por Tucker (1979) [27], se calcula como:

$$NDVI = \frac{NIR - RED}{NIR + RED} \quad (1)$$

Sus valores teóricos oscilan entre -1 y 1 . Los cuerpos de agua, nubes y nieve tienden a producir valores negativos; suelos desnudos y rocas producen valores cercanos a cero; y la vegetación activa se ubica típicamente entre 0.1 y 0.6 , siendo los valores más altos indicadores de mayor vigor y densidad de cobertura vegetal [9].

EVI (Índice de Vegetación Mejorado). El EVI fue desarrollado para corregir limitaciones del NDVI en zonas de vegetación densa (donde el NDVI tiende a saturarse) y para reducir la influencia de la atmósfera (aerosoles) y del fondo del dosel, incorporando la banda azul [10]:

$$EVI = G \cdot \frac{NIR - RED}{NIR + C_1 \cdot RED - C_2 \cdot BLUE + L} \quad (2)$$

donde C_1 y C_2 son coeficientes de corrección atmosférica (habitualmente 6 y 7.5), L es una constante de ajuste del fondo del dosel y G es un factor de ganancia (habitualmente 2.5).

SAVI (Índice de Vegetación Ajustado al Suelo). Propuesto por Huete (1988) [11], introduce un factor L que corrige la influencia del brillo y color del suelo expuesto sobre la señal de vegetación, lo cual es especialmente relevante en zonas de cobertura vegetal rala como la puna:

$$SAVI = \left[\frac{NIR - RED}{NIR + RED + L} \right] \cdot (1 + L) \quad (3)$$

con $L = 0.5$ como valor estándar recomendado para una amplia variedad de coberturas de suelo.

NDMI (Índice de Diferencia Normalizada de Humedad). A diferencia de los tres índices anteriores, que responden principalmente al “verdor” de la vegetación, el NDMI –basado en la propuesta de Gao (1996) [7]– utiliza la combinación de las bandas del infrarrojo cercano y del infrarrojo de onda corta (SWIR) para estimar el contenido de humedad foliar:

$$NDMI = \frac{NIR - SWIR}{NIR + SWIR} \quad (4)$$

Este índice resulta útil para complementar a los índices de “verdor”, ya que aporta información sobre el estrés hídrico de la vegetación, un factor determinante en un entorno semiárido y de alta variabilidad pluviométrica como el altiplano puneño.

2.3 Vegetación Andina y su Relación con Variables Ambientales

En los Andes tropicales, la distribución de la vegetación está fuertemente condicionada por gradientes altitudinales y climáticos. La clasificación macroecológica de los Andes peruanos describe cinturones latitudinales y altitudinales de clima-vegetación que resultan de la combinación de altura, temperatura y precipitación [1]. En términos generales, a mayor altitud disminuyen tanto la temperatura media como, en gran parte del territorio altoandino peruano, la precipitación anual [26]. Esta relación inversa entre altitud y disponibilidad hídrica/térmica es consistente con el hecho de que, en estudios de vegetación altoandina en la propia región de Puno, se han documentado pérdidas de cobertura vegetal productiva asociadas a condiciones ambientales limitantes y al uso antrópico del territorio en localidades de puna [23].

Estos antecedentes permiten anticipar que los índices de vegetación deberían presentar una asociación negativa con la altitud y positiva con la precipitación y la temperatura media, en la medida en que estas últimas favorecen el desarrollo de una cobertura vegetal más vigorosa en las zonas bajas y más húmedas de la región, en contraste con las zonas de puna alta, más frías, secas y con menor densidad de vegetación.

2.4 Fundamentos de Geoestadística

Variable regionalizada y semivariograma. La geoestadística permite modelar formalmente la dependencia espacial de una variable regionalizada $Z(x)$ mediante la función de semivarianza, que cuantifica cómo se incrementa la diferencia esperada entre pares de valores a medida que aumenta la distancia h que los separa [20,15]:

$$\gamma(h) = \frac{1}{2N(h)} \sum_{i=1}^{N(h)} [Z(x_i + h) - Z(x_i)]^2 \quad (5)$$

donde $N(h)$ es el número de pares de puntos separados por el vector distancia h . El gráfico resultante (variograma experimental) permite identificar tres parámetros clave: el *efecto pepita* (nugget, C_0), que refleja variabilidad no explicada a distancias muy cortas o error de medición; la *meseta* (sill, $C_0 + C$), valor de varianza al cual se estabiliza la función; y el *rancho* o alcance (a), distancia a partir de la cual dos observaciones dejan de estar espacialmente correlacionadas.

Modelos teóricos de ajuste. Sobre el variograma experimental se ajustan modelos teóricos continuos – esférico, exponencial o gaussiano, entre otros– que sintetizan la estructura de dependencia espacial y sirven de insumo para la interpolación. La proporción $C_0/(C_0 + C)$ permite clasificar el grado de dependencia espacial en fuerte, moderada o débil [3]. Cuando la variabilidad espacial difiere según la dirección considerada, se habla de *anisotropía*, aspecto que conviene evaluar antes de realizar la interpolación final.

Krigeado ordinario. El krigeado ordinario es un método de interpolación que, a partir del modelo de variograma ajustado, calcula el mejor estimador lineal insesgado del valor de la variable en puntos no muestreados, ponderando las observaciones cercanas según su grado de correlación espacial. A diferencia de otros métodos de interpolación determinísticos (como el inverso de la distancia), el krigeado ordinario provee además la varianza del error de estimación en cada punto, lo cual permite cuantificar la incertidumbre del mapa resultante [13].

Krigeado indicativo. El krigeado indicativo, empleado por Rossi et al. (1994) [25] en la interpolación de imágenes de sensoriamiento remoto y aplicado posteriormente por Lourenço y Landim (2004) [18] al análisis multitemporal de NDVI, consiste en transformar la variable continua original en una variable indicadora binaria a partir de un valor de corte (*cutoff*) z_k [14]. Sobre esta variable transformada se calcula un nuevo semivariograma y se aplica krigeado ordinario, obteniéndose como resultado, para cada punto del espacio, la probabilidad de que el valor real supere (o no) el umbral definido [8]. El procedimiento permite generar mapas de probabilidad en lugar de un simple mapa de clasificación determinística, lo que constituye el principal aporte metodológico del estudio de referencia.

2.5 Antecedentes de Aplicación Conjunta de Geoestadística y Sensoriamiento Remoto

La combinación de geoestadística y datos de sensoriamiento remoto ha sido documentada en diversos contextos: en la caracterización de patrones de paisaje mediterráneo [16], en la segmentación jerárquica de imágenes [30], en la clasificación de pastizales con riesgo epidemiológico en México mediante krigeado indicativo [25], en el estudio de comunidades vegetales del desierto de Mojave [28] y en la discriminación de coberturas litológicas y de uso del suelo mediante correogionalización de imágenes Landsat y SPOT [4,5,2]. En el contexto peruano y particularmente en Puno, el uso de imágenes satelitales para el seguimiento de la vegetación altoandina y el cambio de uso del suelo también ha sido abordado [23], mientras que el krigeado como técnica de interpolación espacial en la región se ha aplicado a otras variables ambientales, como la modelización de ruido ambiental urbano [19], lo que confirma la pertinencia y viabilidad de esta técnica geoestadística en el contexto geográfico de este estudio.

3 Materiales y Métodos

3.1 Área de Estudio

El estudio abarca el departamento de Puno, ubicado en el sureste del Perú entre aproximadamente 13°;00'S y 17°;15'S, con una superficie aproximada de 71 999 km² distribuida en 13 provincias. El territorio presenta un gradiente ecológico pronunciado: la porción centro-sur corresponde al altiplano circunlacustre dominado por el lago Titicaca (≈3810 m s.n.m.), con pastizales naturales, agricultura de secano y ganadería extensiva; hacia el norte y noreste, las provincias de Carabaya y Sandia descienden hacia la ceja de selva y la selva alta, con cobertura boscosa densa y precipitaciones sustancialmente mayores. Este contraste interno resulta central para la interpretación de los resultados. El régimen climático es marcadamente estacional, con precipitaciones concentradas entre diciembre y marzo y un periodo seco entre mayo y agosto.

Los límites administrativos se obtuvieron del shapefile de Límite Distrital 2025 del INEI [12], filtrando los distritos de Puno y disolviendo por el campo **PROVINCIA** en QGIS para obtener la capa de las 13 provincias, posteriormente cargada como *asset* en Google Earth Engine.

3.2 Datos Satelitales y Diseño de Muestreo

El límite político-administrativo provincial se obtuvo originalmente en formato vectorial (*shapefile*) desde la plataforma GeoGPSPerú (<https://www.geogpsperu.com/2019/08/limite-provincial-politico-shapefile.html>). A partir de esta capa espacial, se filtraron las 13 provincias pertenecientes al departamento de Puno y el archivo resultante se importó como un recurso (*asset*) vectorial en la plataforma Google Earth Engine (GEE). Este polígono delimitador sirvió como máscara de recorte para procesar las colecciones de imágenes satelitales correspondientes a *Sentinel-2 SR Harmonized* durante dos periodos climáticos: la estación seca (mayo–agosto 2024) y la estación húmeda (diciembre 2023–marzo 2024).

Para la estructuración del análisis geoestadístico, el proceso de muestreo, extracción y división de los datos se desarrolló en las siguientes etapas:

1. **Generación del Muestreo Espacial:** Utilizando el polígono provincial cargado en GEE, se generó una grilla de 500 puntos aleatorios uniformemente distribuidos sobre el territorio departamental mediante una semilla de aleatorización fija (*seed* = 42) para asegurar la reproducibilidad del diseño.

2. **Extracción Multivariable y Coordenadas:** En cada nodo del muestreo se extrajeron las coordenadas geográficas (longitud y latitud), la altitud del modelo digital de elevación (SRTM), la precipitación acumulada (CHIRPS) y los valores de cuatro índices espectrales (*NDVI*, *SAVI*, *EVI* y *NDMI*).
3. **División y Exportación de Datasets:** Con la información espacial recortada y vinculada a sus respectivas coordenadas, se extrajeron y exportaron dos archivos independientes en formato CSV —uno para la estación seca y otro para la húmeda— constituyendo las bases de datos primarias para su posterior control de calidad y procesamiento geoestadístico en R.

Se aplicó un filtro de rango físico antes de cualquier análisis geoestadístico: $NDVI \in [-1, 1]$, $EVI \in [-1, 1]$ y $SAVI \in [-1.5, 1.5]$. Este paso resultó determinante para la validez del análisis. El EVI, a diferencia del NDVI —cuya construcción normalizada acota estructuralmente su recorrido—, posee un denominador que puede aproximarse a cero sobre superficies de agua, nieve o nubes residuales, produciendo valores varios órdenes de magnitud fuera del rango interpretable. Dado que el semivariograma se construye sobre diferencias al cuadrado (ecuación 5), un único valor extremo domina la nube variográfica y anula la posibilidad de detectar estructura espacial real.

Table 1. Tamaño de muestra por estación, antes y después del control de calidad.

Estación	Puntos exportados	Puntos válidos	Retención (%)
Seca (may–ago 2024)	500	500	100.0
Húmeda (dic 2023–mar 2024)	500	334	66.8

La pérdida de un tercio de las observaciones en la estación húmeda es en sí misma un resultado sustantivo: refleja la contaminación por nubes propia del periodo lluvioso en el altiplano y debe tenerse en cuenta al interpretar la mayor irregularidad de los mapas de esa estación.

3.3 Análisis Variográfico y Krigado Ordinario

A cada semivariograma experimental (ecuación 5) se ajustaron tres modelos teóricos —esférico, exponencial y gaussiano—, seleccionando el definitivo bajo un doble criterio: mínimo error de ajuste por mínimos cuadrados ponderados (SSErr, reportado por `gstat::fit.variogram` [22]) y coherencia física del alcance con la extensión del área de estudio (≈ 250 km de longitud máxima). El segundo criterio no es redundante: en varios casos el modelo con menor SSErr devolvía alcances superiores a la dimensión del propio departamento, situación carente de interpretación geográfica que fue descartada aunque el ajuste numérico fuese superior.

Ajustado el modelo, se realizó krigado ordinario puntual sobre una grilla regular de 2 km de resolución recortada al polígono departamental, con 16 850 nodos de predicción. El estimador es una combinación lineal de las observaciones vecinas:

$$\hat{Z}(x_0) = \sum_{i=1}^n \lambda_i Z(x_i), \quad \text{con} \quad \sum_{i=1}^n \lambda_i = 1 \quad (6)$$

donde los pesos λ_i se obtienen resolviendo el sistema de krigado construido a partir del modelo de semivariograma, de modo que el estimador sea insesgado y de varianza mínima.

3.4 Krigado Indicativo

Para cada observación se definió la variable indicadora respecto de un nivel de corte z_k , adoptando aquí la convención de acumulación por debajo del umbral:

$$i(x; z_k) = \begin{cases} 1, & \text{si } Z(x) \leq z_k \\ 0, & \text{si } Z(x) > z_k \end{cases} \quad (7)$$

Sobre esta variable se calculó el semivariograma indicativo y se aplicó krigeado ordinario puntual. El valor estimado en cada nodo ya no es 0 ni 1, sino un número real en $[0, 1]$ que se interpreta directamente como la probabilidad condicional de no superar el corte:

$$\hat{i}(x_0; z_k) = \hat{P}[Z(x_0) \leq z_k \mid (n)] \quad (8)$$

Es decir, el krigeado indicativo estima punto a punto valores de la función de distribución acumulada condicional de la variable. Si en un nodo el resultado es 0.65, la lectura correcta es que, dados los datos disponibles en su vecindad, existe un 65 % de probabilidad de que el NDVI en ese lugar sea menor o igual al corte considerado.

Definición de los cortes. Siguiendo la lógica de Lourenço y Landim [18], quienes derivaron los suyos del histograma de la variable analizada, se optó por cortes empíricos basados en los terciles de la distribución muestral del NDVI, de modo que las tres categorías resultantes reflejen la estructura de los datos y no umbrales importados de otras regiones. Los cortes fueron $z_1 = 0.176$ y $z_2 = 0.237$ para la estación seca, y $z_1 = 0.177$ y $z_2 = 0.285$ para la estación húmeda. Las clases quedan definidas como Baja ($NDVI < z_1$), Media ($z_1 \leq NDVI < z_2$) y Alta ($NDVI \geq z_2$).

Cálculo de las probabilidades por categoría. Se krigeó cada indicador por separado, obteniéndose dos superficies de probabilidad, $\hat{P}_1 = \hat{P}[Z \leq z_1]$ y $\hat{P}_2 = \hat{P}[Z \leq z_2]$, a partir de las cuales:

$$P(\text{Baja}) = \hat{P}_1; \quad P(\text{Media}) = \hat{P}_2 - \hat{P}_1; \quad P(\text{Alta}) = 1 - \hat{P}_2 \quad (9)$$

Las estimaciones se truncaron al intervalo $[0, 1]$ y se verificó el cumplimiento de la relación de orden $\hat{P}_1 \leq \hat{P}_2$, corrigiendo las escasas violaciones detectadas –un problema conocido del krigeado indicativo, dado que cada corte se estima de forma independiente [8]–. Finalmente, a cada nodo de la grilla se le asignó la categoría con máxima probabilidad estimada entre las tres.

Conviene subrayar la diferencia conceptual con el krigeado ordinario: mientras este último responde a la pregunta “¿cuánto NDVI habría aquí?”, el krigeado indicativo responde a “¿qué tan probable es que aquí la vegetación pertenezca a la categoría X?”. La segunda formulación es más honesta respecto a la incertidumbre y más operativa para la toma de decisiones territoriales.

3.5 Herramientas Computacionales

El procesamiento se realizó en QGIS (límites administrativos), Google Earth Engine (extracción satelital e índices) y R [24], empleando los paquetes `sf` [21] y `sp` para el manejo espacial, `gstat` [22] para semivariogramas y krigeado, y `ggplot2` [29] junto con `patchwork`, `viridis`, `ggspatial` y `ggrepel` para la visualización y cartografía.

4 Resultados y Discusión

4.1 Estadística Descriptiva

Los histogramas de la estación seca (Fig. 1) muestran distribuciones unimodales con asimetría positiva para NDVI, SAVI y EVI, con una cola derecha correspondiente a los puntos localizados en las provincias de ceja de selva. El NDMI, en cambio, se distribuye en torno a valores negativos (moda aproximada en -0.15), coherente con un territorio de baja humedad foliar y amplia presencia de suelo desnudo y pastizal seco: valores negativos de NDMI indican predominio de la reflectancia SWIR sobre la del NIR, patrón característico de superficies con bajo contenido de agua.

Distribución de índices de vegetación — Puno (Época Seca)




Fig. 1. Distribución de los índices de vegetación (histogramas y curvas de densidad) para la estación seca. Nótese la asimetría positiva de NDVI, SAVI y EVI, y el desplazamiento del NDMI hacia valores negativos.

El diagrama de caja comparativo (Fig. 2) permite contrastar ambas estaciones simultáneamente. La mediana del NDVI es ligeramente superior en la estación húmeda, pero la diferencia es notablemente modesta: la media se mantiene en el orden de 0.22–0.23 en ambos periodos. Esto sugiere que, a escala departamental, el efecto de la estacionalidad sobre el *nivel medio* de verdor es menor que su efecto sobre la *organización espacial* del verdor, hallazgo que se confirma en el apartado siguiente. La dispersión es mayor en la estación húmeda para todos los índices, reflejo de la heterogeneidad espacial de las precipitaciones; el EVI presenta el rango más amplio y el mayor número de valores extremos, confirmando su mayor sensibilidad numérica en el rango bajo de reflectancia; y el NDMI es el único índice con mediana negativa en ambas estaciones, aunque menos negativa en la húmeda, consistente con un mayor contenido de humedad foliar durante el periodo lluvioso.




Fig. 2. Comparación estacional de los índices de vegetación mediante diagramas de caja. Provincias del departamento de Puno.

4.2 Semivariogramas Experimentales y Modelos Ajustados

Table 2. Modelo de semivariograma seleccionado por índice y estación.

Índice	Estación	Modelo	Alcance (km)
NDVI	Seca	Gaussiano	108.4
SAVI	Seca	Gaussiano	108.4
EVI	Seca	Exponencial	74.8
NDMI	Seca	Gaussiano	90.4
NDVI	Húmeda	Esférico	16.9
SAVI	Húmeda	Esférico	16.2
EVI	Húmeda	Gaussiano	75.1
NDMI	Húmeda	Esférico	117.6

El resultado más relevante del análisis variográfico es el contraste estacional en el alcance de la dependencia espacial (Tabla 2). En la estación seca, el NDVI y el SAVI presentan alcances superiores a los 100 km, indicando que la similitud entre puntos se mantiene a escala regional. En la estación húmeda, esos mismos índices reducen su alcance a 16 km to 17 km, en torno a un sexto de la distancia anterior.

La interpretación agroecológica es directa. Durante la estación seca la variabilidad del verdor está gobernada por factores estructurales de gran escala y variación suave –el gradiente altitudinal, la transición altiplano/ceja de selva, la aridez general del territorio–, que producen una superficie continua y de cambio

gradual. Durante la estación húmeda, en cambio, la lluvia actúa como un forzante espacialmente discontinuo: los eventos convectivos característicos del altiplano generan parches de humedad y, por tanto, parches de respuesta vegetal a escala de decenas de kilómetros, fragmentando la estructura espacial. Dicho de otro modo, en estación seca Puno se comporta como un *gradiente*; en estación húmeda, como un *mosaico*.

Es importante señalar que este hallazgo no habría sido detectable a partir de la estadística descriptiva, dado que la media del NDVI apenas varía entre estaciones. Es precisamente el análisis geoestadístico el que revela que, bajo una media casi idéntica, la organización espacial subyacente es radicalmente distinta, lo que constituye el argumento más sólido a favor de incorporar herramientas geoestadísticas al análisis de series de índices de vegetación [6,17].

El comportamiento del NDMI merece un comentario aparte: es el único índice cuyo alcance *aumenta* en la estación húmeda (117.6 km frente a 90.4 km). Una hipótesis plausible es que, al saturarse el perfil de humedad superficial durante el periodo lluvioso, la señal hídrica se homogeneiza regionalmente, mientras que la respuesta fotosintética –capturada por NDVI y SAVI– permanece condicionada por factores locales de suelo, pendiente y uso agrícola. Esta hipótesis requeriría validación con datos de humedad de suelo *in situ*.

4.3 Krigeado Ordinario

Los mapas de krigeado ordinario para la estación seca muestran superficies suaves y de transición gradual, consecuencia directa de los alcances amplios y del modelo gaussiano ajustado. La Fig. 3 presenta el caso del NDVI, representativo del patrón general observado en los cuatro índices: un gradiente noreste–suroeste claramente definido, con los valores más altos (> 0.30) concentrados en el norte de Carabaya y el sector central de Sandia –zonas de ceja de selva y selva alta– y los más bajos en Lampa, San Román y el sur de El Collao, sectores del altiplano con predominio de pastizal seco, suelo desnudo y uso agropecuario extensivo.




Fig. 3. Interpolación por krigeado ordinario del NDVI para la estación seca. La superficie continua y de transición suave es consecuencia del alcance amplio (108.4 km) del modelo gaussiano ajustado.

Los mapas de la estación húmeda (Fig. 4) presentan una apariencia visual radicalmente distinta: en lugar de superficies suaves se observan estructuras de tipo “ojo de buey” en torno a los puntos de muestreo, con transiciones abruptas entre ellos. Este comportamiento es la manifestación cartográfica directa del alcance corto ajustado: cuando el alcance es de 16 km y la grilla tiene 2 km de resolución, la influencia de cada

observación se extingue a pocos nodos de distancia y el estimador tiende rápidamente a la media global en las zonas sin datos próximos. No se trata, por tanto, de un artefacto de procesamiento, sino de la expresión fiel de una estructura espacial débil y de corto alcance, agravada por la reducción del tamaño muestral a 334 puntos.

Interpolación por Kriging de índices de vegetación — Época Húmeda

Provincias del departamento de Puno, Perú




Fig. 4. Interpolación por krigeado ordinario de los cuatro índices para la estación húmeda. Las estructuras de tipo “ojo de buey” reflejan el alcance corto del semivariograma y el menor número de observaciones válidas.

4.4 Krigeado Indicativo y Clasificación de la Cobertura Vegetal

Aplicando el procedimiento descrito en la Sección 3.4 se obtuvieron, para cada estación, dos superficies de probabilidad y, a partir de ellas, la clasificación final por máxima probabilidad. Los resultados se resumen en la Tabla 3.

Table 3. Distribución de la grilla de predicción ($n = 16850$ nodos) por categoría de vegetación. Los cortes son específicos de cada estación (seca: 0.176 y 0.237; húmeda: 0.177 y 0.285).

Categoría	Estación seca		Estación húmeda		Tendencia
	Nodos	%	Nodos	%	
Baja	3463	20.6	3315	19.7	Ligera baja
Media	5044	29.9	4580	27.2	Baja
Alta	8343	49.5	8955	53.1	Sube
Total	16 850	100.0	16 850	100.0	

Lectura de la comparación estacional. En la estación húmeda aumenta la proporción de territorio clasificado como categoría Alta (de 49.5 % a 53.1 %), a costa de una reducción simultánea de las categorías Media (-2.7 puntos porcentuales) y Baja (-0.9 puntos), resultado coherente con la expectativa agroecológica de que el periodo lluvioso incrementa el vigor vegetativo del altiplano.

Sin embargo, este hallazgo requiere una precisión metodológica que constituye uno de los puntos más interesantes del trabajo. Dado que los cortes se definieron sobre los terciles *propios de cada estación*, por construcción cada categoría contiene aproximadamente un tercio de los *puntos de muestreo* en ambos periodos. Lo que la Tabla 3 compara, por tanto, no es el nivel absoluto de verdor, sino cómo se reparten espacialmente esas categorías sobre el territorio. Y aquí el resultado es doblemente significativo: el umbral que define la categoría Alta es *más exigente* en la estación húmeda ($z_2 = 0.285$ frente a 0.237 en la seca) y, pese a ello, esa categoría *ocupa más superficie*. Durante el periodo lluvioso no solo suben los valores del índice: las zonas de verdor elevado se vuelven espacialmente más extensas y más contiguas.

Un segundo aspecto que merece explicación es la asimetría entre la proporción muestral y la proporción cartográfica. Cada categoría contiene un tercio de los puntos de muestreo, pero la categoría Alta ocupa cerca de la mitad del área. Esto no constituye una inconsistencia: refleja que las zonas de NDVI alto –el norte de Carabaya y Sandia– son provincias de gran extensión territorial y comportamiento espacial homogéneo, mientras que las categorías Baja y Media se distribuyen de forma fragmentada e intercalada en el altiplano. El muestreo aleatorio pondera por número de puntos; el mapa pondera por superficie, y la divergencia entre ambas ponderaciones es en sí misma información territorial relevante.

Estación seca. El mapa de clasificación (Fig. 5) muestra una estructura territorial nítida. Se observa predominio de la categoría Alta en el norte: Carabaya, Sandia y el sector septentrional de San Antonio de Putina y Melgar aparecen como bloques continuos, continuidad que es consecuencia del alcance amplio del modelo gaussiano ajustado y resulta geográficamente coherente con la transición hacia la selva alta. En el altiplano circunlacustre –Lampa, San Román, Puno, El Collao y Chucuito– domina en cambio un mosaico intercalado de parches Baja y Media de contornos irregulares, consistente con el uso agropecuario extensivo, la fragmentación predial y la alternancia entre áreas cultivadas, pastizal degradado y afloramientos rocosos. Se identifican núcleos de categoría Baja bien definidos en el centro de Lampa y en el sur de El Collao, sectores de mayor aridez relativa, así como un enclave de categoría Alta en Moho y el sector ribereño de Huancané, atribuible a la influencia térmica moderadora del lago Titicaca sobre la agricultura de ribera.




Fig. 5. Clasificación espacial de la vegetación mediante kriging indicativo. NDVI, estación seca. Cortes: Baja < 0.176; Media 0.176–0.237; Alta ≥ 0.237 . Cada nodo de la grilla recibe la categoría de mayor probabilidad estimada entre las tres.

Estación húmeda. El mapa correspondiente (Fig. 6) presenta bloques de mayor tamaño y contornos más abruptos, con una expansión visible de la categoría Alta hacia el centro del departamento (Azángaro, Huancané, San Antonio de Putina) y hacia el sector oriental de Puno y Chucuito. La comparación visual entre las Figs. 5 y 6 resume gráficamente el hallazgo central del trabajo: el mapa de la estación seca es un gradiente de transiciones suaves, mientras que el de la estación húmeda es un mosaico de bloques compactos y bordes netos.

Esa apariencia en bloques responde, no obstante, a dos causas de naturaleza distinta que conviene no confundir. Por un lado refleja un fenómeno real: la fragmentación de la estructura espacial documentada en el análisis variográfico (alcance de 16.9 km). Por otro incorpora un componente artificial derivado del menor número de observaciones válidas (334 frente a 500) combinado con ese alcance corto, que produce amplias zonas de la grilla dominadas por la información de un único punto de muestreo próximo y, en consecuencia, clasificadas de manera uniforme. La comparación entre ambos mapas debe realizarse con la debida cautela metodológica: los patrones de la estación seca son considerablemente más confiables.




Fig. 6. Clasificación espacial de la vegetación mediante krigeado indicativo. NDVI, estación húmeda. Cortes: Baja < 0.177; Media 0.177–0.285; Alta $\geq$ 0.285. Nótese el mayor tamaño de los bloques y la nitidez de los bordes respecto a la estación seca (Fig. 5).

4.5 Limitaciones

Por transparencia metodológica corresponde explicitar las principales limitaciones del estudio. La densidad de muestreo es baja: con 500 puntos para 72 000 km² la distancia media entre observaciones vecinas es del orden de 12 km, lo que compromete la capacidad de resolver estructuras espaciales de alcance corto, precisamente las dominantes en la estación húmeda. No se realizó validación cruzada *leave-one-out* de los modelos, cuya incorporación permitiría reportar RMSE y error medio estandarizado. El análisis variográfico asumió isotropía, pese a que la orientación NO–SE de la cordillera hace razonable esperar anisotropía geométrica –el propio estudio de referencia la detectó en su superficie variográfica–. Finalmente, las covariables auxiliares extraídas (altitud y precipitación) se emplearon solo como apoyo interpretativo; su incorporación formal mediante krigeado con deriva externa constituye la extensión natural de este trabajo, dado el fuerte control altitudinal esperable sobre el NDVI en un territorio de gradiente pronunciado.

5 Conclusiones

El departamento de Puno presenta un patrón estacional claro y estadísticamente detectable en la *estructura* de su variabilidad espacial: dependencia de largo alcance en la estación seca ($\approx$ 108 km para NDVI y SAVI) frente a corto alcance en la estación húmeda ($\approx$ 16 km to 17 km). Dado que las medias del índice resultaron prácticamente idénticas entre estaciones ($\approx$ 0.22–0.23), el forzante climático estacional actúa principalmente fragmentando la organización espacial del verdor más que elevando su nivel medio, hallazgo que la estadística descriptiva por sí sola no habría permitido detectar.

El krigeado indicativo permite pasar de un valor interpolado –cuya precisión aparente puede resultar engañosa– a una probabilidad de pertenencia a una categoría, formato más adecuado para la toma de decisiones agrícolas y ambientales por explicitar la incertidumbre asociada a cada localización. La comparación

estacional indica una expansión de la categoría Alta desde el 49.5 % del territorio en estación seca hasta el 53.1 % en estación húmeda, resultado especialmente significativo por producirse pese a que el umbral que define dicha categoría es más exigente en el periodo lluvioso: durante las lluvias las zonas de verdor elevado no solo alcanzan valores mayores, sino que se vuelven espacialmente más extensas y contiguas.

La distribución territorial obtenida es coherente con la estructura ecológica conocida del departamento, con predominancia de categoría Alta en las provincias de ceja de selva (Carabaya, Sandia) y mosaico Baja–Media en el altiplano circunlacustre, consistente con el uso agropecuario extensivo y la menor cobertura vegetal natural de ese sector. Todo el procedimiento fue reproducido con datos de acceso abierto y software libre, sin trabajo de campo, lo que abre la posibilidad de un monitoreo territorial sistemático y de bajo costo para la región.

References

1. Macroecología de los Andes peruanos: cinturones de clima y vegetación. Instituto Francés de Estudios Andinos (IFEA), Lima, Perú
2. Berberoglu, S., Lloyd, C.D., Atkinson, P.M., Curran, P.J.: The integration of spectral and textural information using neural networks for land cover mapping in the Mediterranean. *Computers & Geosciences* **26**(4), 385–396 (2000). [https://doi.org/10.1016/S0098-3004\(99\)00119-3](https://doi.org/10.1016/S0098-3004(99)00119-3)
3. Cambardella, C.A., Moorman, T.B., Novak, J.M., Parkin, T.B., Karlen, D.L., Turco, R.F., Konopka, A.E.: Field-scale variability of soil properties in central Iowa soils. *Soil Science Society of America Journal* **58**(5), 1501–1511 (1994). <https://doi.org/10.2136/sssaj1994.03615995005800050033x>
4. Chica-Olmo, M., Abarca-Hernández, F.: Radiometric coregionalization of Landsat TM and SPOT HRV images. *International Journal of Remote Sensing* **19**(5), 997–1005 (1998). <https://doi.org/10.1080/014311698215739>
5. Chica-Olmo, M., Abarca-Hernández, F.: Computing geostatistical image texture for remotely sensed data classification. *Computers & Geosciences* **26**(4), 373–383 (2000). [https://doi.org/10.1016/S0098-3004\(99\)00118-1](https://doi.org/10.1016/S0098-3004(99)00118-1)
6. Curran, P.J.: The semivariogram in remote sensing: an introduction. *Remote Sensing of Environment* **24**(3), 493–507 (1988). [https://doi.org/10.1016/0034-4257\(88\)90021-1](https://doi.org/10.1016/0034-4257(88)90021-1)
7. Gao, B.C.: NDWI — a normalized difference water index for remote sensing of vegetation liquid water from space. *Remote Sensing of Environment* **58**(3), 257–266 (1996). [https://doi.org/10.1016/S0034-4257\(96\)00067-3](https://doi.org/10.1016/S0034-4257(96)00067-3)
8. Goovaerts, P.: *Geostatistics for Natural Resources Evaluation*. Oxford University Press, New York (1997)
9. Holben, B.N.: Characteristics of maximum-value composite images from temporal AVHRR data. *International Journal of Remote Sensing* **7**(11), 1417–1434 (1986). <https://doi.org/10.1080/01431168608948945>
10. Huete, A., Didan, K., Miura, T., Rodriguez, E.P., Gao, X., Ferreira, L.G.: Overview of the radiometric and biophysical performance of the MODIS vegetation indices. *Remote Sensing of Environment* **83**(1–2), 195–213 (2002). [https://doi.org/10.1016/S0034-4257\(02\)00096-2](https://doi.org/10.1016/S0034-4257(02)00096-2)
11. Huete, A.R.: A soil-adjusted vegetation index (SAVI). *Remote Sensing of Environment* **25**(3), 295–309 (1988). [https://doi.org/10.1016/0034-4257\(88\)90106-X](https://doi.org/10.1016/0034-4257(88)90106-X)
12. Instituto Nacional de Estadística e Informática: Límite distrital 2025 [shapefile]. Lima, Perú (2025), distribuido a través de GeoGPS Perú
13. Isaaks, E.H., Srivastava, R.M.: *An Introduction to Applied Geostatistics*. Oxford University Press, New York (1989)
14. Journel, A.G.: Nonparametric estimation of spatial distributions. *Journal of the International Association for Mathematical Geology* **15**(3), 445–468 (1983). <https://doi.org/10.1007/BF01031292>
15. Journel, A.G., Huijbregts, C.J.: *Mining Geostatistics*. Academic Press, London (1978)
16. Lacaze, B., Rambal, S., Winkel, T.: Identifying spatial patterns of Mediterranean landscapes from geostatistical analyses of remotely-sensed data. *International Journal of Remote Sensing* **15**(12), 2437–2450 (1994). <https://doi.org/10.1080/01431169408954253>
17. Lark, R.M.: Geostatistical description of texture on an aerial photograph for discriminating classes of land cover. *International Journal of Remote Sensing* **17**(11), 2115–2133 (1996). <https://doi.org/10.1080/01431169608948763>
18. Lourenço, R.W., Landim, P.M.B.: Estudo da variabilidade do “índice de vegetação por diferença normalizada/ndvi” utilizando krigagem indicativa. *HOLOS Environment* **4**(1), 38–55 (2004)
19. Marín: Modelamiento del ruido ambiental urbano mediante interpolación geoestadística en la ciudad de Puno. Master’s thesis, Universidad Nacional del Altiplano, Puno, Perú (2018)
20. Matheron, G.: Principles of geostatistics. *Economic Geology* **58**(8), 1246–1266 (1963). <https://doi.org/10.2113/gsecongeo.58.8.1246>
21. Pebesma, E.: Simple features for R: standardized support for spatial vector data. *The R Journal* **10**(1), 439–446 (2018). <https://doi.org/10.32614/RJ-2018-009>

22. Pebesma, E.J.: Multivariable geostatistics in S: the gstat package. *Computers & Geosciences* **30**(7), 683–691 (2004). <https://doi.org/10.1016/j.cageo.2004.03.012>
23. Quispe: Análisis multitemporal de la cobertura vegetal altoandina en el distrito de Cabana, Puno (2000–2016). Master’s thesis, Universidad Nacional del Altiplano, Puno, Perú (2021)
24. R Core Team: R: A Language and Environment for Statistical Computing. R Foundation for Statistical Computing, Vienna, Austria (2024), <https://www.R-project.org/>
25. Rossi, R.E., Dungan, J.L., Beck, L.R.: Kriging in the shadows: geostatistical interpolation for remote sensing. *Remote Sensing of Environment* **49**(1), 32–40 (1994). [https://doi.org/10.1016/0034-4257\(94\)90057-4](https://doi.org/10.1016/0034-4257(94)90057-4)
26. Servicio Nacional de Meteorología e Hidrología del Perú (SENAMHI): Atlas climático del Perú. Lima, Perú
27. Tucker, C.J.: Red and photographic infrared linear combinations for monitoring vegetation. *Remote Sensing of Environment* **8**(2), 127–150 (1979). [https://doi.org/10.1016/0034-4257\(79\)90013-0](https://doi.org/10.1016/0034-4257(79)90013-0)
28. Wallace, C.S.A., Watts, J.M., Yool, S.R.: Characterizing the spatial structure of vegetation communities in the Mojave Desert using geostatistical techniques. *Computers & Geosciences* **26**(4), 397–410 (2000). [https://doi.org/10.1016/S0098-3004\(99\)00120-X](https://doi.org/10.1016/S0098-3004(99)00120-X)
29. Wickham, H.: ggplot2: Elegant Graphics for Data Analysis. Springer-Verlag, New York, 2 edn. (2016)
30. Woodcock, C.E., Harward, V.J.: Nested hierarchical scene models and image segmentation. *International Journal of Remote Sensing* **13**(16), 3167–3187 (1992). <https://doi.org/10.1080/01431169208904109>